

TAC1	PROPOSTA DE TRABALHO
------	----------------------

TÍTULO:

Detecção de ataques em aplicações web hospedadas na nuvem pública utilizando aprendizado de máquina aplicado à análise de logs.

AUTORES:

Gabriel Cândido

Nicolas José Duarte de Campos

ORIENTADOR(A):

Francisco Diego Garrido da Silva

CO-ORIENTADOR(A):

Reinaldo do Valle Junior

1. RESUMO

O trabalho propõe o desenvolvimento de uma solução utilizando aprendizado de máquina para detectar ataques em aplicações web por meio da análise de logs gerados a partir de requisições HTTP em ambientes de nuvem pública. Inicialmente, são estudados algoritmos de Machine Learning e conjuntos de dados adequados para o treinamento. A metodologia envolve, primeiro, a realização de ataques simulados em ambiente controlado. Em seguida, são realizados ataques reais em uma aplicação na nuvem, permitindo a coleta de dados mais variados. Esses logs serão utilizados para treinar e avaliar o modelo, que busca diferenciar requisições legítimas de maliciosas. Por fim, o desempenho do modelo é analisado para verificar a eficácia na detecção de intrusões, evidenciando o potencial do uso de técnicas de aprendizado de máquina como uma abordagem promissora para fortalecer a segurança de aplicações web.

2. FUNDAMENTAÇÃO TEÓRICA

As aplicações web são sistemas de software executados diretamente em navegadores, dispensando instalação local e permitindo acesso remoto por meio da internet. Esse modelo favorece a escalabilidade, a facilidade de manutenção e a ampla acessibilidade, sendo amplamente adotado por organizações modernas (AMAZON WEB SERVICES, 2023).

Nesse cenário, o crescimento do uso da internet tem impulsionado significativamente a adoção dessas aplicações. De acordo com a International Telecommunication Union, cerca de três quartos da população mundial possuem acesso à internet, o que evidencia a relevância e o alcance global das tecnologias web. Entretanto, essa expansão também amplia a superfície de ataque, tornando a segurança um fator crítico.

2.1 Segurança em Aplicações Web

A segurança em aplicações web tem como objetivo garantir a confidencialidade, integridade e disponibilidade das informações (RAZZAQ, 2014). Nesse sentido, essas aplicações estão constantemente expostas a ameaças que exploram vulnerabilidades, como falhas de autenticação, validação inadequada de entradas e exposição de dados sensíveis.

Além disso, a ausência de mecanismos eficazes de proteção pode resultar em vazamento de informações, indisponibilidade de serviços e prejuízos financeiros, reforçando a necessidade de soluções de segurança mais robustas.

2.2 Computação em Nuvem

A computação em nuvem é um modelo que permite acesso conveniente e sob demanda, por meio da rede, a um conjunto compartilhado de recursos computacionais configuráveis, como redes, servidores, armazenamento, aplicações e serviços, que podem ser rapidamente provisionados e liberados com mínimo esforço de gerenciamento ou interação com o provedor (NIST, 2025).

Nesse contexto, os principais modelos de serviço incluem Infraestrutura como Serviço (IaaS), Plataforma como Serviço (PaaS) e Software como Serviço (SaaS). Esses modelos oferecem vantagens como escalabilidade, alta disponibilidade e redução de custos operacionais (AMAZON WEB SERVICES, 2023), sendo amplamente utilizados na hospedagem de aplicações web modernas.

No entanto, a centralização de recursos também aumenta a necessidade de mecanismos avançados de segurança e monitoramento.

2.3 Ataques Cibernéticos e Detecção

Os ataques cibernéticos representam uma das principais ameaças às aplicações web, explorando vulnerabilidades para obter acesso não autorizado ou comprometer sistemas. Entre os ataques mais comuns, destacam-se SQL Injection, Cross-Site Scripting (XSS) e ataques de força bruta.

De forma geral, o SQL Injection explora falhas na validação de entradas para manipular consultas ao banco de dados, podendo comprometer informações sensíveis. O Cross-Site Scripting (XSS), por sua vez, permite a inserção de scripts maliciosos em páginas web, afetando usuários legítimos. Já os ataques de força bruta utilizam tentativas sucessivas para descobrir credenciais de acesso.

Diante desse cenário, a identificação e mitigação de vulnerabilidades tornam-se fundamentais para garantir a segurança de sistemas de informação (MONTEIRO; BASTOS; RODAMILANS, 2024).

2.4 Detecção de Ataques

Como forma de mitigar essas ameaças, destacam-se os Sistemas de Detecção de Intrusão (Intrusion Detection Systems – IDS), responsáveis por monitorar atividades em sistemas e redes com o objetivo de identificar comportamentos suspeitos ou maliciosos (SCARFONE; MELL, 2007). Esses sistemas são amplamente utilizados na proteção de aplicações web.

No contexto dessas aplicações, a análise de logs configura-se como uma abordagem relevante para detecção de intrusões, pois permite identificar padrões de ataque, como tentativas de força bruta, SQL Injection e XSS (TEIXEIRA; MENDONÇA, 2026). Entretanto, o grande volume de dados torna inviável a análise manual, exigindo o uso de técnicas automatizadas.

Nesse cenário, algoritmos de Machine Learning, como o Random Forest, são utilizados para classificar automaticamente eventos como normais ou maliciosos, aumentando a eficiência na detecção de ataques (BAILETTI; GAD; SHAH, 2016).

2.5 Machine Learning Aplicado à Segurança

O aprendizado de máquina, um subconjunto da inteligência artificial, capacita sistemas a aprender com dados e tomar decisões inteligentes sem programação explícita. Sua capacidade de identificar padrões, anomalias e tendências em grandes volumes de dados posiciona o Machine Learning como um forte aliado na detecção de ameaças cibernéticas (OKOLI; OBI; ADEWUS; ABRAHAMS, 2024).

De modo geral, os algoritmos de Machine Learning podem ser classificados em três categorias: supervisionado, semi-supervisionado e não supervisionado. No aprendizado supervisionado, utiliza-se um conjunto de dados rotulado para identificar ataques e requisições normais. Já no semi-supervisionado, apenas dados normais são rotulados, de modo que desvios são considerados anômalos. Por fim, no não supervisionado, não há rotulação dos dados, o que pode aumentar a ocorrência de falsos positivos (MANE et al., 2022).

Com base nas técnicas adotadas por Javier (2023), neste trabalho são utilizados algoritmos supervisionados, como K-Nearest Neighbors (KNN), Random Forest e Support Vector Machine (SVM). O KNN classifica dados com base na proximidade entre instâncias, o Random Forest utiliza múltiplas árvores de decisão para melhorar a precisão e reduzir o sobreajuste, enquanto o SVM busca encontrar um hiperplano que separa classes de forma ótima no espaço de características.

Dessa forma, algoritmos de Machine Learning apresentam-se como ferramentas eficazes na área de cibersegurança, sendo capazes de identificar padrões de comportamento, analisar características como horários e frequência de acesso, e detectar anomalias indicativas de ataques (OKOLI; OBI; ADEWUS; ABRAHAMS, 2024).

3. OBJETIVOS

O objetivo principal do trabalho é desenvolver um modelo de aprendizado de máquina que possa detectar ataques a partir da análise de logs em uma aplicação web hospedada em uma nuvem pública analisando requisições HTTP.

- Analisar o modelo de aprendizado de máquina a ser utilizado, assim como os datasets utilizados para o treinamento.
- Realizar ataques simulados em uma rede local para testes.
- Realizar ataques reais em uma aplicação hospedada na nuvem.
- Extrair logs da aplicação para a inteligência artificial analisar requisições válidas e ataques.
- Analisar o desempenho do modelo de Machine Learning por meio de métricas de avaliação, como acurácia, precisão, recall e F1-score, a fim de interpretar os resultados obtidos e fundamentar conclusões sobre sua eficácia na detecção de ataques.

4. MATERIAIS E MÉTODOS

4.1 Equipamentos e Materiais

Para o desenvolvimento deste trabalho, serão utilizados recursos de uso pessoal, como um computador com capacidade suficiente para execução de máquinas virtuais, processamento de dados e treinamento de modelos de aprendizado de máquina. O sistema operacional utilizado será o Kali Linux, que já possui ferramentas voltadas para testes de segurança, como o Metasploit Framework e o Hydra, que serão utilizados na realização de ataques controlados. Também será utilizada uma VPN, com o objetivo de garantir maior segurança e isolamento durante os testes.

A parte de aprendizado de máquina será desenvolvida utilizando a linguagem Python. A aplicação web que será utilizada como alvo dos ataques será desenvolvida com Spring Boot no backend, utilizando autenticação com JWT, e React no frontend. O armazenamento dos dados, tanto na aplicação quanto na análise de logs pelo Machine Learning, será utilizado o PostgreSQL. A aplicação será disponibilizada em ambiente de nuvem pública por meio da Amazon Web Services, permitindo que os testes sejam realizados em um cenário mais próximo do real.

4.2 Estratégia Metodológica

O desenvolvimento do trabalho será dividido em etapas, de forma a organizar melhor a construção da solução proposta.

Inicialmente, será feita uma revisão bibliográfica dos conceitos relacionados à segurança de aplicações web, sistemas de detecção de intrusões e uso de aprendizado de máquina nesse contexto. Em seguida, serão analisados e utilizados datasets como CICIDS2017 e CSIC-2010 que servirão para o treinamento inicial do modelo, antes da realização dos ataques.

Após essa etapa, será desenvolvido o modelo de aprendizado de máquina utilizando o algoritmo Random Forest. Esse modelo será treinado previamente com os datasets selecionados, com o objetivo de aprender a diferenciar comportamentos normais de possíveis ataques.

Com o modelo já treinado, será utilizada a aplicação web que servirá como alvo dos testes. Em seguida, serão realizados ataques simulados em ambiente local e na aplicação hospedada na nuvem, utilizando ferramentas específicas. Durante esses testes, serão coletados logs das requisições HTTP geradas, contendo tanto acessos legítimos quanto atividades maliciosas.

Na etapa seguinte, esses logs serão utilizados como entrada para o modelo previamente treinado, que será responsável por analisar as requisições e identificar possíveis ataques.

Por fim, os resultados obtidos serão analisados com base em métricas como acurácia, precisão e recall, permitindo avaliar o desempenho do modelo na detecção de intrusões.



Diagrama de Fluxo de Dados do trabalho

5. PLANO DE TRABALHO

Tabela 1 - Metas estabelecidas para a proposta.

METAS	DESCRIÇÃO
1	Revisão Bibliográfica
2	Revisar e configurar aplicação web
3	Configuração inicial da Machine Learning e do Dataset
4	Realizar ataques iniciais na aplicação localhost
5	Entrega do Relatório de Qualificação
6	Apresentação do Relatório de Qualificação
7	Avaliação inicial do desempenho do modelo de Machine Learning na detecção de ataques
8	Subir aplicação na nuvem pública
9	Realizar ataques na aplicação na nuvem pública
10	Analisar Resultados Finais dos Ataques e da Machine Learning
11	Entrega da Monografia
12	Apresentação da Monografia
13	Submissão do Artigo

Tabela 2 - Cronograma proposto para cumprimento das metas.

	MESES									
METAS	FEV	MAR	ABR	MAI	JUN	JUL	AGO	SET	OUT	NOV
1	x	x								
2		x								
3		x	x							
4			x							
5			x	x						
6					x					
7						x				
8						x	x			
9							x			
10							x	x		
11								x	x	
12										x
13										x

6. VIABILIDADE DE EXECUÇÃO

Para a realização do projeto, será necessário utilizar as ferramentas metasploit-framework e hydra, que estão instaladas no sistema operacional

Kali-Linux. Será utilizado também a linguagem de programação Python, para o desenvolvimento da Machine Learning. Os recursos utilizados serão de uso pessoal, não sendo necessário parceria com empresas.

Utilizaremos também uma aplicação web desenvolvida com a linguagem de programação Java Spring Boot/JWT no backend e React no frontend. Além de um banco de dados em PostgreSQL.

Utilizaremos os recursos de computação em nuvem da Amazon Web Services, para colocar a aplicação desenvolvida, a ser atacada, em um ambiente de nuvem pública.

A pesquisa será conduzida em ambiente doméstico e virtual, utilizando infraestrutura própria e serviços em nuvem. Os experimentos serão realizados tanto em rede local quanto em ambiente de nuvem, garantindo a análise em diferentes contextos.

O projeto contará com o apoio técnico dos professores Francisco Diego Garrido da Silva e Reinaldo do Valle Junior, que auxiliarão na orientação metodológica, na validação dos experimentos realizados e na análise dos resultados obtidos. Esse acompanhamento contribui para garantir a consistência científica e a correta aplicação das técnicas de aprendizado de máquina e segurança da informação.

7. RESULTADOS ESPERADOS E DISSEMINAÇÃO

Espera-se que o trabalho resulte em:

- Modelo de aprendizado de máquina funcional capaz de identificar requisições HTTP maliciosas, ataques Brute Force e XSS, em aplicações web hospedadas em nuvem pública, diferenciando acessos legítimos de acessos maliciosos.
- Validação prática do modelo treinado por meio de ataques simulados em ambiente local e ataques reais em aplicação hospedada na nuvem, permitindo avaliar a eficácia em cenários mais próximos da realidade.
- Métricas de desempenho (acurácia, precisão, recall e F1-score) que possibilitam mensurar a capacidade do modelo em detectar intrusões.
- Complemento às soluções existentes de segurança, demonstrando que a aplicação de técnicas de Machine learning na análise de logs pode reforçar mecanismos tradicionais de defesa, como firewalls e sistemas de detecção de intrusão.
- Monografia acadêmica como produto final, descrevendo detalhadamente a metodologia, os experimentos realizados e os resultados obtidos.
- Artigo científico.
- Possível disponibilização do código e dataset próprio em repositório público (como GitHub), contribuindo para futuras pesquisas.

A principal contribuição do trabalho é a validação da aplicação de aprendizado de máquina na detecção de ataques em ambientes reais de nuvem

pública. Assim, reforçando a importância do uso entre técnicas de inteligência artificial e práticas de cibersegurança com o intuito de aumentar a resiliência de aplicações web frente a ataques cibernéticos.

REFERÊNCIAS BIBLIOGRÁFICAS

AMAZON WEB SERVICES. **O que é uma aplicação web?** Disponível em: <https://aws.amazon.com/pt/what-is/web-application/>. Acesso em: 30 mar. 2026.

BAILETTI, Tony; GAD, Mahmoud; SHAH, Ahmed. Intrusion learning: an overview of an emergent discipline. **Technology Innovation Management Review**, v. 6, n. 2, p. 15–20, 2016. Disponível em: <http://timreview.ca/article/964>. Acesso em: 02 abr. 2026.

INTERNATIONAL TELECOMMUNICATION UNION (ITU). **ITU's Facts and Figures 2025 shows steady progress in connectivity, while highlighting gaps in quality and affordability**. 2025. Disponível em: https://www.itu.int/en/mediacentre/Pages/PR-2025-11-17-Facts-and-Figures.aspx?utm_source=chatgpt.com. Acesso em: 30 mar. 2026.

JAVIOR, Sonia Francis. **Log-based intrusion detection system using machine learning**. 2023. Dissertação (Mestrado em Artificial Intelligence) – National College of Ireland, School of Computing, Irlanda. Disponível em: <https://norma.ncirl.ie/7363/>. Acesso em: 1 abr. 2026.

MANE, Deepak T.; SANGVE, Sunil; UPADHYE, Gopal; KANDHARE, Sahil; MOHOLE, Saurabh; SONAR, Sanket; TUPARE, Satej. Detection of anomaly using machine learning: a comprehensive survey. **International Journal of Emerging Technology and Advanced Engineering**, v. 12, n. 11, nov. 2022. Disponível em: https://doi.org/10.46338/ijetae1122_15. Acesso em: 31 mar. 2026.

MONTEIRO, João Eduardo Zanin; BASTOS, Renato Henrique Aguiar; RODAMILANS, Charles Boulhosa. **Avaliação de sistemas de detecção e prevenção de intrusos em ambientes**. São Paulo: Universidade Presbiteriana Mackenzie (UPM), 2023.

LEE, Craig A.; BOHN, Robert B.; MICHEL, Martial. **The NIST Cloud Federation Reference Architecture**. Gaithersburg: National Institute of Standards and Technology (NIST), 2025. (NIST Special Publication 500-332). DOI: <https://doi.org/10.6028/NIST.SP.500-332>. Acesso em: 2 abr. 2026.

TEIXEIRA, Otávio Noura; MENDONÇA, Eudes Danilo. An integrated cybersecurity approach: integrating Wazuh and base CVE (MITRE) for vulnerability management in a corporate environment. **Revista Gênero e Interdisciplinaridade**, v. 7, n. 1, 2026. Disponível em:

<https://www.periodicojs.com.br/index.php/gei/article/view/2819>. Acesso em: 2 abr. 2026.

OKOLI, Ugochukwu Ikechukwu; OBI, Ogugua Chimezie; ADEWUSI, Adebunmi Okechukwu; ABRAHAMS, Temitayo Oluwaseun. Machine learning in cybersecurity: A review of threat detection and defense mechanisms. **World Journal of Advanced Research and Reviews**, v. 21, n. 1, p. 2286–2295, 2024. Disponível em: <https://doi.org/10.30574/wjarr.2024.21.1.0315>. Acesso em: 2 abr. 2026.

RAZZAQ, Abdul; LATIF, Khalid; AHMAD, H. Farooq; HUR, Ali; ANWAR, Zahid; BLOODSWORTH, Peter Charles. Semantic security against web application attacks. **Information Sciences**, v. 254, p. 19–38, 2014. Disponível em: <https://doi.org/10.1016/j.ins.2013.08.007>. Acesso em: 1 abr. 2026.

SCARFONE, Karen; MELL, Peter. **Guide to Intrusion Detection and Prevention Systems (IDPS): recommendations of the National Institute of Standards and Technology**. Gaithersburg, MD: National Institute of Standards and Technology, 2007. Disponível em: <https://doi.org/10.6028/NIST.SP.800-94>. Acesso em: 1 abr. 2026.

Assinatura do(a) orientador(a): _____